

# Segmentación del árbol vascular en retinografías

Pedro Guijas Bravo

Diciembre 2021

## 1. Introducción

La retinografía es una técnica utilizada para obtener imágenes en color de la retina. Dichas imágenes son usadas en medicina para el diagnóstico de diversas enfermedades, la más relevante, la diabetes. Este tipo de diagnóstico es no invasivo y la segmentación de la estructura vascular a partir de imágenes de retinas puede ser de gran ayuda para el diagnóstico clínico.

En la figura 1 podemos ver una retinografía del dataset público (Digital Retinal Images for Vessel Extraction (DRIVE)). De este dataset en particular, hablaremos en el apartado de evaluación de los diferentes métodos desarrollados.

Para el tratamiento de la imagen nos centraremos únicamente en el canal verde, puesto que es el que más información aporta. En las figuras 2 y 3, se puede apreciar que la figura 2 aporta un mayor contraste.




Figura 1: Ejemplo Retinografía




Figura 2: Canal Verde de Retinografía



Figura 3: Retinografía en blanco y negro

De un simple vistazo, podremos deducir a priori, problemas con los cambios de intensidad del fondo a lo largo de la imagen. El disco óptico y algunas zonas con tendencia a oscurecerse pueden provocar que diferentes algoritmos no produzcan los resultados deseables.

## 2. Evaluación

Antes de proceder con las diferentes aproximaciones debemos establecer los criterios de evaluación.

Como hemos comentado en la Introducción, disponemos de un dataset de Retinografías junto con su segmentación realizada a mano. Dicha segmentación realizada a mano será considerada como la segmentación ideal y evaluaremos nuestras aproximaciones en base a comparaciones directas.

Para obtener las diferencias haremos uso de la **matriz de confusión**, la cual nos permite manejar el número de verdaderos negativos, falsos positivos, falsos negativos y verdaderos positivos respectivamente.

Por motivo del alto número de píxeles en el fondo y la poca relevancia de estos, no valdrá cualquier métrica, no todas serán representativas. Un claro ejemplo sería un detector que segmente todo como fondo, habrá métricas como el MRC o la especificidad que nos proporcionen valores optimistas, siendo esto falso.

La **sensibilidad** o **recall** y la **precisión** serán pues indicadores perfectos de la bondad. Estas mismas nos permitirán tener noción de la sub-segmentación o sobre-segmentación que se pueda estar dando. Podremos condensar estos dos valores en uno, la **similitud**, esta representará la distancia al segmentador perfecto tomando como referencia las 2 métricas mencionadas.

A mayores, he visto conveniente tener en cuenta el **Coefficiente de Similitud de Dice**.

$$precision = \frac{VP}{VP + FP} \quad (1)$$

$$recall = \frac{VP}{VP + FN} \quad (2)$$

$$DSC = \frac{2VP}{2VP + FN + FP} \quad (3)$$

### 3. Investigación previa

Antes de centrarme en dos métodos en concreto, he realizado una investigación sobre las diversas formas de abordar el problema. Desde un punto de vista general he intentado enfocar el problema desde las siguientes perspectivas:

- **Segmentación basadas en Modelos Deformables (snakes):** la principal razón por la que no me he decantado por este tipo de métodos es debido a la inicialización del modelo, esta debería partir del disco óptico e ir expandiéndose minimizando la función de energía. Es indudable que se podrían obtener muy buenos resultados, pero siendo consecuentes con la duración de esta práctica he decidido no abordarlo.
- **Segmentación basadas en Regiones y umbralización:** La umbralización fue considerada como un primer método de entrada al problema, finalmente, los sorprendentes resultados de la **umbralización local** hicieron de este el 1º método seleccionado. Destacar que se han llegado a implementar otros métodos basados en watersheds y clustering pero con resultados poco satisfactorios.
- **Vesselness filters:** Más concretamente el filtro de **Frangi**, comunmente usado para resaltar estructuras tubulares gracias a la detección de crestas (Hessian). Este será el 2º método, el no conocer esta aproximación y resultarme tan interesante han sido la razón de la elección.
- **Aproximaciones con Machine Learning:** Descartadas debido a que personalmente ya había trabajado con las mismas y como objetivo propio me planteé investigar aproximaciones más algorítmicas.
- **Aproximaciones basadas en detectores de bordes:** Aplicación de Sobel y trabajo sobre el mismo con operadores morfológicos y diversas técnicas. En primera instancia este iba a ser el 2º método, pero debido al atractivo del filtro de Frangi he decidido no centrarme en esta aproximación. En la figura 4 se puede apreciar que los resultados podrían ser realmente prometedores.



Figura 4: Detector de bordes Sobel

## 4. Metodologías

### 4.1. Preprocesado

Como ya hemos comentado en la Introducción nos centraremos en el canal Verde. El preprocesamiento constará de las siguientes fases:

- **Redimensión:** el tamaño de la imagen es duplicado.
- **Obtenemos Marco:** tiene como objetivo dejar el fondo de la retinografía completamente negro.
- **Contrast Limited Adaptive Histogram Equalization (CLAHE):** Una ecualización global para resaltar las características de la imagen no tiene gran efecto debido a la gran cantidad de píxeles negros que se encuentran en el fondo (no nos interesan). CLAHE Ecualizará el histograma centrándose en un ratio de vecindad y permitiendonos definir los niveles de contraste entre regiones (para no amplificar ruido), lo cual nos permitirá resaltar los vasos muy adecuadamente. (véase figura 5)
- **Filtros de Medianas:** 7x7. Es cierto que los filtros de medianas pueden eliminar ramificaciones pequeñas, pero los métodos no son capaces de detectarlas de todas formas (y obtenemos mejores resultados en las otras ramificaciones).




Figura 5: CLAHE

### 4.2. Adaptive Threshold

Como hemos comentado en la Investigación previa, la umbralización parece ser un buen método de entrada al problema, haremos uso de una umbralización local. La umbralización global no se comporta bien, debido a las diferentes condiciones de iluminación en la retinografía y al gran número de píxeles negros en el fondo.

En la figura 6 puede observarse que el resultado de esta operación es bastante aceptable, pero tenemos una gran cantidad de ruido que debemos eliminar. Para eliminar el ruido extraemos de la imagen todas las estructuras cuya área sea inferior a un cierto umbral.

#### 4.2.1. Evaluación

Tas aplicar las correspondientes métricas podremos observar los resultados en la tabla 1. Se aprecian carencias en la detección de pequeñas ramificaciones, por lo contrario, los




Figura 6: Adaptive Threshold con Ruido




Figura 7: Adaptive Threshold sin Ruido




Figura 8: Solución Óptima

vasos mediano y grandes los detecta sin problema. Los vasos más grandes pueden tener huecos y mitigaremos este efecto en el apartado de mejoras.

Recall	Precision	Similitud	DSC
71.4 %	74.2 %	71.5 %	71.4 %

Cuadro 1: Resultados 1º Método

#### 4.2.2. Mejoras

Destacar que la realización de este método fue una sucesión de mejoras y ajustes en parámetros partiendo de una umbralización muy simple. Como última mejora, dentro de sus limitaciones, realizamos un cierre para tratar de unir huecos pequeños provocados por los tamaños de ventana en métodos locales. Tampoco podemos usar un elemento estructurante muy grande porque si no uniríamos zonas.

Recall	Precision	Similitud	DSC
72.2 %	76.6 %	72.9 %	73.0 %

Cuadro 2: Resultados 1º Método tras mejora

### 4.3. Filtros Rígidos (Frangi)

En primera instancia nos centramos en obtener unos resultados aceptables, de este modo, la elección de parámetros y la comprensión del método ha sido un proceso pausado y cuidadoso. Los resultados del filtro han sido binarizados y se han eliminado estructuras de poco área. En la figura 9 puede observarse la segmentación producida (para la retinografía del ejemplo 1), posteriormente hemos intentado mejorar el método.

#### 4.3.1. Evaluación

Los resultados muestran que nos encontramos ante una técnica más robusta, la calidad del resultado parece mejor que la anterior técnica. Nos encontramos con problemas de ruido, sobre todo en el disco óptico y algunas regiones con ruido de forma tubular. También podremos apreciar problemas en algunas bifurcaciones y ramificaciones pequeñas.

Los resultados de las métricas se encuentran en la tabla 3.




Figura 9: Frangi

Recall	Precision	Similitud	DSC
76.8 %	67.7 %	71.0 %	70.7 %

Cuadro 3: Resultados 2º Método

#### 4.4. Mejoras

Para mitigar el ruido se han extraído máscaras que nos indican donde se encuentran los píxeles más blancos a partir de un clahe de alto contraste de la imagen original. También se ha experimentado con morfología, aun que sin grandes resultados. En el preprocesado se ha añadido una especie de suavizado morfológico con un elemento estructurante bajo para no perder pequeñas estructuras.

Recall	Precision	Similitud	DSC
75.0 %	72.6 %	72.8 %	72.7 %

Cuadro 4: Resultados 2º Método tras mejora

## 5. Conclusiones

Los resultados obtenidos son bastante similares. El **1º método** ha demostrado grandes resultados pese a la simplicidad del mismo. El **2º método** demuestra comportarse mejor puesto que no es tan 'de propósito general' como una umbralización.

Ambos métodos presentan problemas con las ramificaciones pequeñas, estas no castigan mucho las métricas debido a que sus áreas son ínfimas en comparación a las ramificaciones grandes. En Frangi hemos tenido que buscar un equilibrio entre ruido con forma tubular y la detección de pequeños vasos.

Finalmente, es interesante comentar que una imagen referencia en concreto nos baja las métricas medias, la imagen junto con la segmentación perfecta y la obtenida con Frangi las podremos observar en la figura 10,11 y 12 respectivamente. La multitud de vasos segmentados erroneamente en la imagen, realmente existen y se pueden apreciar en la imagen original.



Figura 10: Retinografía 23




Figura 11: Segmentación Manual 23




Figura 12: Segmentación Frangi 23